

ICUの判断はなぜ外れるか

誤りをバイアスとノイズに分け、個人の注意ではなく仕組みで減らす — 誤りの2つの型・診断エラーの実測・見逃しの構造・ノイズを減らす・予測が結果を作る領域・AIを3層で読む・エビデンスのノイズ・落とし穴

聖路加国際病院 集中治療科

対象：研修医・専攻医・看護師

最終更新 2026-10-09

ST. LUKE'S ICU / CLINICAL JUDGMENT

ICUの判断はなぜ外れるか — 最初に押さえる6点

大きな数字は剖検研究・コホート研究・RCTの値。注釈は要点と出典

ICU死亡例の剖検で見つかる主要な
診断乖離 (%)

18.5

治療を変えていたはずのclass Iが7.5%。25年間ほぼ横ばい

出典 Tejerina 2012 (834剖検)

診断エラーに入室24時間以内に気づけた割合 (%)

33.3

予定外入室256例の7.0%が診断エラー。誤った作業診断の18件中7件が「敗血症」

出典 Bergl CCM2019

同じ827例の院内死亡予測のAUC
(医師→APACHE IV)

0.68 → 0.83

差の正体は賢さではなく、全例に同じ重みを当てる一貫性

出典 Crit Care 2025 (SICS)

独立した判断を4人で平均したときの
ノイズ

1 /2

判断数の平方根で減る。上級医が先に話すと独立性が崩れて効かない

出典 Crit Care 2025

心停止後に初回値だけで判断したときの偽陽性率 (%)

18.2

瞳孔+角膜反射。14日窓で繰り返し測ると3.0%

出典 Crit Care 2026 (101例)

院内LLMのカルテ抽出と手作業データベースの一致 (%)

97.5

不一致を裁定すると14変数中10変数でLLMのほうが正しかった

出典 npj Digit Med 2026

ICUの判断の誤りは、個人の知識不足や不注意として語られがちです。この資料で持ち帰るのは、①誤りを一定方向にずれる**バイアス**と方向の定まらない**ノイズ**に分け、ノイズは注意力ではなく手順の固定と独立した判断の平均化で減らす、②診断エラーは技術の進歩では減っておらず、症候群のラベルを貼った瞬間に推論が止まるので、「どこか感染か／感染でないなら何か」を返し、翌朝に入室時の診断を見直す、③予測モデルとAIは「賢さ」ではなく「一貫性」を供給する道具として読み、AUCより先にどこで・何例で検証したか、較正、出力を誰が検証するかを問う、の3点です。スコアの作りと較正・SMRの読み方は**重症度スコアと予後予測**、心停止後の神経予後予測の手順は**心停止後ケア**、予後の数字と治療方針の決定の分け方は**ICUの終末期と意思決定**が正本です。

§1 誤りは2種類ある — 一定方向のずれ（バイアス）と、ばらつき（ノイズ）では対策が違う

医療で語られてきた判断の誤りは、ほとんどがバイアスでした。この章では、もう1つの誤りであるノイズを定義し、ICUがその影響を受けやすい場所であることを確かめます。

この章のポイント


- 1 目の前の誤りがどちらの型かを先に見る
- 2 ノイズは平均しても消えないと知る
- 3 標準から外した理由を記録する

1-1. 定義 — バイアスは平均のずれ、ノイズは1回ごとのばらつき

的に矢を射ると、全体が同じ方向にずれるのがバイアス（bias、系統誤差）、的の周りに散らばるのがノイズ（noise、ランダム誤差）で、同じ幅だけ減らせば全体の誤差への寄与は等価です（図1） [Noise2021]。



バイアス=全体が同じ方向にずれる



ノイズ=ばらばらに散らばる

図1. 左は矢が右上に固まってずれている（バイアス）。右は的の周囲に散らばっている（ノイズ）。

図の読み方 — 左を直すには「なぜ右上にずれるのか」という原因を突き止め、右を直すには判断の手順そのものを固定します。「アンカリングに気をつけよう」「無意識のバイアスをなくそう」はどれも左の対策です [ノイズCC2025]。ノイズが議論されにくいのは、バイアスは1人を追えば見えるのに、ノイズは複数の人が同じ症例を判断しないと見えないからです。品質管理の言葉では、バイアスの逆が正確度（accuracy）、ノイズの逆が精密度（precision）にあたります。

1-2. ICUはくじ引きになりうる — システムノイズは3種類で、患者をまたいで蓄積する

ICUは「担当医が誰でも同じ判断に落ち着く」という前提で動いていますが、ノイズはこの前提を裏切り、似た患者が担当医によって違う予後予測と違う治療を受けるくじ引き（lottery effect）を生むので、場面ごとにどの型のノイズが乗るかを見ておきます（表1） [ノイズCC2025]。

表1 | システムノイズの3分類

ノイズの型	意味	ICUでの具体例
レベルノイズ level noise	臨床医ごとの平均的な判断の水準の差	ある医師は常に介入寄り、別の医師は常に慎重。ICU入室の可否、HCU・SDUへの振り分けの閾値の差 [ノイズCC2025]
安定パターンノイズ stable pattern noise	臨床医×患者特性の安定した交互作用	特定の併存症をもつ患者に一貫して高い死亡確率をつける。楽観と悲観の差ではなく、患者因子への重みづけの違い [ノイズCC2025]
機会ノイズ occasion noise	同じ臨床医の場面に よるばらつき	疲労・時間帯・気分。同じ症例を別の機会に見ると判断が変わる。深夜のRRSコールの判断はここに入る [ノイズCC2025]

！ 注意 — ノイズは相殺されない

ノイズは患者をまたいで打ち消し合うのではなく、蓄積します（compounding） [ノイズCC2025]。「平均すれば正しい」は成り立ちません。患者にとって重要なのは、自分が受けたその1回の判断だからです。

1-3. 経験は一貫性を保証しない — 熟達の3条件が、ICUではそろいにくい

直感的な熟達には①明確でタイムリーなフィードバック、②予測因子と転帰の安定した関係、③それを学ぶ機会の3条件が要りますが、ICUは転帰が出るのが数か月先で、その後を見届けないことが多く、経験豊富な医師のICU死亡予測は医学生より有意に正確とはいえませんでした [Kahneman&Klein2009] [Cox SICS2021]。

経験が広げるのは知識と鑑別の幅であって、一貫性ではありません。もう1つの誤解は「ばらつきは仕方ない、最後は個別化だ」で、個別化は本物のときも単なるノイズのときもあり、外からは区別できません。区別する方法は、標準の手順から外した理由を記録し

て後から見返せるようにすることだけです。教育の目標も「当てる力」から「同じ手順を踏む力」へ置き直します

[診断エラー解説ICM2025]。

§2 診断エラーは技術では減っていない — 剖検で18.5%、予定外入室で7.0%、気づけたのは3分の1

誤りを減らす前に、どれだけ起きているかを物差しごとに確かめます。剖検とカルテレビューは別の物差しで、数字は分母ごと引用します。

この章のポイント

- 1 見落としの6疾患を声に出して除外する
- 2 入室翌朝に作業診断を見直す
- 3 頻度は分母と判定法を添えて引用する

2-1. 剖検が測った乖離 — 834剖検で主要乖離18.5%、25年間横ばいで、見落としの上位は6疾患

スペイン単施設の連続834剖検では、主要な診断乖離が154例（18.5%）、うち生前に分かっていれば治療が変わり転帰も変わったかもしれないclass I（Goldman分類）が63例（7.5%）で、25年間の乖離率は横ばいでした（class I中央値8.5%、class II中央値13%、 $p=0.2997$ 、Goodman-Kruskal $\tau=0.0025$ ） [Tejerina2012] [Goldman NEJM1983]。

見逃された所見は多い順に肺塞栓24・肺炎23・二次性腹膜炎12・侵襲性アスペルギルス症8・感染性心内膜炎8・心筋梗塞8の6疾患です [Tejerina2012]。class IIは95例（11.4%）、剖検でも死因不明が22例（2.6%）でした。内訳は時代とともに入れ替わり、肺炎は直近6年で診断精度が下がり（2001–03年8例→2004–07年11例）、心筋梗塞と腸間膜虚血はほぼ消え、肺塞栓だけは一貫した変化がありません。

表2 | 見落としの構造 — なぜ見逃されたか

疾患	見逃しの構造
肺塞栓	螺旋CTがあってもなお24例。末梢の塞栓が主体だった可能性 [Tejerina2012]
肺炎（人工呼吸中）	同グループの253剖検で「X線浸潤影+3臨床基準のうち2つ」は感度64.8%・特異度36%。3基準すべてを要求すると感度15.5%・特異度91% [Tejerina2012]
ARDS	382剖検との比較で臨床定義の感度75%・特異度84% [Tejerina2012]
二次性腹膜炎	主因は消化管穿孔。意識障害・麻薬・免疫抑制・人工呼吸が腹部所見を隠す [Tejerina2012]
感染性心内膜炎・心筋梗塞	重症患者では心疾患への疑いが向きにくい。剖検例のうちICU滞在中に一度でも心電図をとられていたのは55%だけ。心内膜炎は経食道心エコーでも見落としうる [Tejerina2012]

2-2. カルテレビューが測った診断エラー — 予定外入室の7.0%で、24時間以内に気づけたのは33.3%

米国の内科系ICU（26床）で、生存例を含む予定外入室256例を改変Safer Dxの2段階カルテレビューにかけると18例（7.0%）が診断エラーで、ICUチームが入室24時間以内に気づけたのは6例（33.3%）だけだったので、作業診断は入室時に1行で書き、翌朝に見直します（表3） [Bergl CCM2019]。

表3 | 予定外ICU入室256例の診断エラー

指標	数値
診断エラー	18／256（7.0%）。対象は2,105件から無作為抽出した434件を除外基準でふるった256例 [Bergl CCM2019]
入室24時間以内に気づけたもの	6／18（33.3%）
害あり（6段階で「害なし」が0件）	18／18。うち「相当の害」以上6件（33.3%）、軽微な害12件（66.7%）、死亡に寄与2件（11.1%）
多変量で残った因子	女性（入室時OR 5.18、24時間OR 11.6）、入室時qSOFA≥2（OR 5.73）
DEER分類で多かった失敗	競合する診断に重みを置きすぎた100%／その診断を考えるのが遅れた89%／最終診断への考慮不足83%／病歴の重みづけの失敗67%

誤った作業診断の側に「敗血症／敗血症性ショック」が18件中7件あり、最終診断は膿瘍・骨髓炎・穿孔・心内膜炎・化膿性関節炎というソースコントロールの要る病巣か、右心不全・HFpEF・ループス心膜心筋炎という感染ではない病態でした [Bergl CCM2019]。DEER（Diagnosis Error Evaluation and Research）分類は、病歴・診察・検査の解釈・鑑別の組み立て・フォローアップのどの工程で失敗したかを分ける枠組みで、最多が「競合する診断に重みを置きすぎた」だったことは、失敗が情報不足ではなく手持ちの情報の重みづけの誤りだったことを示します。

！注意 — 「すべてのエラーに害があった」を単独で引用しない

6段階の害スケールで「害なし」が1件もなかったという意味で、3分の2は軽微な害です。防ぎえたかは判定しておらず、判定者間一致も測っておらず、介入も検証していません [Bergl CCM2019]。

2-3. 数字は分母ごと引用する — 7.0%・18.5%・23%は互いに検算できない

7.0%（ICU予定外入室256例のカルテレビュー）、18.5%（ICU死亡834剖検）、23%（内科入院2,428例からの推定）は分母も判定法も違うので互いに検算できず、文献上の幅は入院患者全体で5～40%、ICU患者で7～32%です [Bergl CCM2019] [Tejerina2012] [診断エラー解説ICM2025]。

剖検は死亡例のうち剖検に回った症例だけ（Tejerinaの剖検率は30.3%）、カルテレビューはエラーと判定された症例だけを見ます。剖検率は世界的に下がり続けており、これは診断エラーが減ったことではなく、見る手段が減ったことを意味します。剖検・カルテレ

ビュー・レジストリはそれぞれ別の物差しとして育てます。

根拠を見る（臨床で拾えた頻度と、剖検で見た頻度）

ドイツの剖検登録（29施設・COVID-19剖検1,129例）では、ECMO例の頭蓋内出血が21%（非ECMO例3%）に達し、ECMO例の78%で直接死因か原死因とされましたが、生前のELSO登録では同じ合併症が4.5%でした [ECMO剖検DeRegCOVID]。臨床で拾えた頻度と体を開けて見た頻度が5倍違うという、剖検乖離と同じ構造です。ただし死亡例だけの剖検で、生存例を含むECMO患者全体の発生率ではありません。

§3 なぜ見逃すか — 症候群のラベルで推論が止まり、作業システムがそれを支える

見逃しの原因は、臨床医の頭の中（認知）と、臨床医を取り巻く作業システムの両方にあります。どちらか一方だけを直しても、同じ失敗が別の形で戻ってきます。

この章のポイント

- 1 ラベルを受け取ったら鑑別を言わせる
- 2 徴候と診断基準の足元を知っておく
- 3 報告できる土壌を先に作る

3-1. 認知の罫 — アンカリング・想起・早期閉鎖・確証は、疲労と過重労働で強くなる

診断エラーの認知的要因は、初期印象に固定されるアンカリング、思い出しやすい診断に飛びつくアベイラビリティ・バイアス、推論を早く打ち切る早期閉鎖、疑っている診断を支える情報だけを拾う確証バイアス、そして過信と自覚されない知識の穴で、いずれも高ストレス・過重労働・疲労で強くなります [診断エラー解説ICM2025]。

○ その場でやる

- ・ 「敗血症です」には「どこの感染か／感染でないなら何か」を返す
- ・ 原因不明の増悪では見落としの6疾患を声に出して除外し、心電図をとる
- ・ 診断に合わない所見を1つ以上カルテに書く
- ・ 48～72時間で反応が想定と違えば「今、初診なら何を考えるか」を口に出す

× やらない

- ・ 申し送りの病名をそのまま次に渡す
- ・ 矛盾する検査値を「ノイズだろう」と読み飛ばす
- ・ 直近に経験した症例と似た病名から考え始める
- ・ 侵襲的な手技や機器の数値に気をとられ、病歴と診察を省く

3-2. 症候群アプローチの限界 — 敗血症・ARDS・VAPの臨床定義は、感度も特異度も高くない

敗血症・ARDS・せん妄といった症候群は異質な病態をひとまとめにし、ARDSの臨床定義は剖検に対して感度75%・特異度84%、VAPの「浸潤影+2基準」は感度64.8%・特異度36%なので、症候群名がついても診断が済んだとは考えません（表4）

[診断エラー解説ICM2025] [Tejerina2012]。

表4 | よく使う診断的判断の性能

評価法	基準	性能	読み方
VAPの臨床診断（剖検が正解）	浸潤影+3 臨床基準のうち2つ	感度64.8%・特異度36%	3人に1人を取りこぼす。「VAPを否定した」とは言えない [Tejerina2012]
同上	3基準すべて	感度15.5%・特異度91%	厳しくすると、ほとんど拾えない
ARDSの臨床定義（剖検が正解）	—	感度75%・特異度84%	症候群の定義そのものが不完全
qSOFA（入院を要する市中肺炎1,045例）	院内死亡のC統計量	0.69（CURB-65 0.75、PSI 0.74と有意差なし）	3項目を数えるだけのスクリーニングで、精度で勝つ道具ではない。詳細は重症度スコアの資料 [qSOFA-CAP JIC2018]
瞳孔対光反射+角膜反射（心停止後）	14日窓の最終値／初回値だけ	偽陽性率3.0%／18.2%	繰り返し測って初めてこの特異度になる [心停止後予後予測CC2026]

ベッドサイドの徴候も足元は弱く、ショックの臨床徴候を25研究・67,894名で集めた系統的レビューで有効とされたのは、末梢の灌流・温度の低下、毛細血管再充満時間の延長、網状皮斑、ショック指数0.7～0.8以上の4つだけでした。頻脈・頻呼吸・尿量低下を支持した研究はごく少数で、意識の変化・発汗・末梢動脈の触知を検討した報告は1件もありません [ICM2023徴候SR]。英国178 ICUで

は、ショックへのPOCUSが54%で診断か治療を変えた一方、実施率も54%どまりでした [エコー診断変更ICM2024]。「見れば変わる」ことと「見ているか」は別の問題です。

3-3. 作業システムとして分解する — SEIPSの5要素で見ると、過剰診断も診断エラーになる

診断は臨床医1人の推論ではなく、人・課題・道具・組織・環境が作る作業システムの産物で、人間工学の枠組みSEIPSで分解すると対策が設計の言葉になり、見落としと同じく過剰診断（広域抗菌薬を漫然と続けるなど）も診断エラーとして扱えます（表5）

[SEIPS ICM2026]。

表5 | SEIPSで診断プロセスを分解し、対策を置く

要素	ICUでの具体例	設計の対策
人	知識・疲労・チーム内の役割認識	批判的思考の教育とモデリング、認知バイアスを明示的に議論する [診断エラー解説ICM2025]
課題	症候群ラベルへの依存、鑑別の組み立て方	診断タイムアウト（「もし今初診なら」を口に出す）、症状から組み立てる診断ワークアップ
道具・技術	電子カルテの設計、アラートの出方	診断チェックリスト、構造化した申し送り
組織	当直体制、引き継ぎの頻度、M&Mの運用	診断の質を専任で見る役割、多職種のレビュー、標準化したレビュー手法（Revised Safer Dx Instrument、修正DEER分類）
物理・社会環境	深夜の人員、多職種の情報共有の経路	非難しない安全文化。ICU後フォローアップ外来を診断の検証装置として使う

SEIPSの論考は短報で新規データはなく、ICUへの適用そのものは検証されていません [SEIPS ICM2026]。

3-4. 報告できる土壌が先 — 重大エラー後に離職を考える割合は日本30.8%、米国8.6%

職種・診療科・経験年数を1:1でマッチした日米比較で、日本の医療者は重大エラーへの関与の報告が少ないのに（11.9%対73.0%）罪責感・不安・訴訟への恐怖が強く、重大エラー後に離職を考える割合は30.8%対8.6%だったので、診断エラーを測る前に、報告できる仕組みを先に作ります [第二犠牲者CC2026]。

支援体制を高く評価しながら実際には同僚に相談しない（48.6%対61.1%）という乖離もあり、提言は「助けを求める負担を個人からシステムへ移す」、つまり申請制をやめ、重大事例の後のチームデブリーフィングを既定の手順にすることです [第二犠牲者CC2026]。土台の劣化も指摘されており、研修医が患者と直接接している時間は13%で、外来の診断エラーの半数以上は不十分な病歴聴取と身体診察に帰せられます [ベッドサイドNEJM2025]。

§4 ノイズを減らす — 手順を固定し、独立した判断を平均し、後から見返せる形で残す

ノイズを減らす道具は2つ、アルゴリズム（同じ変数を同じ重みで統合する）と、独立した判断の平均化です。どちらにも副作用と成り立つ条件があります。

この章のポイント

- 1 意見は同時に出し、上級医は最後に話す
- 2 スコアは測り方の標準化に使う
- 3 作業診断と逸脱の理由を1行で残す

4-1. 一貫性はそれだけで効く — 同じ827例で医師のAUC 0.68、APACHE IV 0.83

同じSICSコホート827例で、医師の院内死亡予測はAUC 0.68 (0.63–0.73)、APACHE IVは0.83 (0.79–0.88) で、著者らはこの差を「モデルが賢いから」ではなく、全例に同じ重みづけを一貫して当てられるから、と説明しています [ノイズCC2025]。

専門家の判断をまねた線形モデル (judgmental bootstrapping) は元の専門家を上回り、単位重みやランダム重みの「雑な」線形モデルでも、一貫性のおかげで専門家を上回りうるということが知られています [Dawes1979]。臨床的予測と統計的予測のどちらが優れるかは、1954年にMeehlが体系的に検討して以来続く論争で、「経験を大事にすべきだ」と「決まった手順に従うべきだ」の対立は、多くがこの論争の再演です。「アルゴリズムはブラックボックスだから信用できない」には、人の判断もまた、後から正確に言語化できず実験で検証しにくいブラックボックスだ、と対にして問い返せます [ノイズCC2025]。


！ 注意 — 著者自身がつけた2つの限定

医師とAPACHE IVでは使える情報量が違い (APACHE IVは24時間分の最悪値を使う)、この数字は「AIが医者より賢い」ではなく「一貫性はそれだけで効く」の根拠として読みます [ノイズCC2025]。また、この一貫性の議論は予測モデル・スコア・線形モデルの話で、同じ入力に同じ出力を返さない生成AI (LLM) には当てはまりません (§6-3)。

4-2. 独立した判断の平均化 — 4人で平均するとノイズは半分、ただし上級医が先に話すとは崩れる

独立した判断のランダムな誤差は平均すると相殺され、ノイズは判断数の平方根に比例して減る (4人なら1/2) ので、朝のカンファと家族面談前のカンファでは意見を同時に出し、最も影響力の強い人が最後に話します (図2) [ノイズCC2025]。

独立に出してから議論=ばらつきが打ち消し合う



上級医が先に話す=全員が引きずられる




図2. 独立性が壊れる瞬間。左は4人の意見がばらばらに出て、束ねると真値の近くに集まる。右は上級医が先に話し、残る3人が同じ向きにそろろう。

図の読み方 — 右では4人いても実質1人分の判断しかなく、平均化の効果は大きく損なわれます。付箋・チャットの同時投稿・事前フォームで意見を先に集めれば、追加のコストはほとんどかかりません。平均化はノイズには効きますが、全員が同じ方向にずれているバイアスには効きません。

根拠を見る（ノイズ監査の設計）

自施設のノイズを数字にする方法として、臨床医20名に同じ50症例の死亡確率を推定してもらい、そのうち症例3を「症例51」として再提示するパイロット設計が示されています（低リスクとして倫理審査は免除）

[ノイズCC2025]。症例間のばらつきでレベルノイズとパターンノイズを、同じ症例の2回の差で機会ノイズを分けられます。人がアルゴリズムの出力を手がかりの1つとして統合する方法（holistic synthesis）が精度を上げるか下げるかは、まだ分かっていません。他分野では、人は例外を作りすぎてノイズを増やし精度を下げるという知見があります [ノイズCC2025]。

4-3. スコアは個人に数字を告げる道具ではなく、測り方をそろえる道具 — 40年の教訓


重症度スコアの40年が残した教訓は「群を比較する道具であって、個人の予後を言い当てる道具ではない」で、個人に当てると開発時のバイアスを永続させ倒錯した行動を招くので、スコアで死亡確率を告げることは避け、スコアが求める同じ変数を全員が同じ方法で集めることにだけ使います [LastingLegacy ICM2022]。

「アルゴリズムでばらつきを消せ」というノイズ論と「個人に使うな」というスコア論は、こう分けると両立します。前者の標準化はくじ引きを減らし、後者の数値の提示は倒錯した行動を招きます。ただしスコアの中にもノイズは残ります。APACHEにもSOFAにもGCSのような判断に依存する変数が入っており、SOFAの成り立ちと測り方を整理した総説は、多施設での評価者間の標準化が鍵だとしています [SOFA標準化CritCare2019]。GCS・RASSの評価者教育とダブルチェックが今も効くのはこのためで、日勤帯と当直帯で採点の規則がそろっているかを点検します。

4-4. 予測モデルはAUCの前に3点を見る — 識別能と較正は独立に壊れ、外部検証済みは少数派


予測モデルは①識別能（死ぬ人と死なない人を並べられるか、AUC）、②較正（「10%」と言った人が本当に10%死ぬか、較正プロット・Brier score・SMR）、③外的妥当性（どこで・何例・何イベントで検証したか）の3点で読み、AUCの高さだけで使えと判断しません（図3） [ノイズCC2025] [JROD JIC2021]。

識別能＝順位づけできるか



較正＝確率が当たっているか

実際の頻度



言った確率

図3. 識別能と較正は独立に壊れる。左は生存（白丸）と死亡（黒丸）の分かれ方、右は理想線（点線）からのずれ。

図の読み方 — 左が完璧でも右が壊れていることがあります、その逆もあります。APACHE III-jを日本のJIPAD 33,557例に当てるとAUROC 0.915で識別能は無傷でしたが、SMR 0.48で死亡を実測の2倍以上に見積もっていました [JROD JIC2021]。「誰が危ないかは分かるが、死亡確率は当てられない」状態で、較正のずれは再較正で直せますが、識別能の低下は係数の作り直しか新しい予測因子でしか直りません。

この領域のモデルを広く集めると、独立したコホートで外部検証を経ているものは少数派です（表6）。公開ICUデータベースを使った4,648本の書誌計量では、AUROCの中央値は0.798（範囲0.511～1.000）で、AUROCと引用インパクトには相関がありませんでした（Spearman $\rho=0.05$ 、 $p=0.10$ ） [MIMIC書誌CC2026]。臨床で信じてよいのは、十分なイベント数・外部検証・較正の実数値の3つがそろったときで、読むときの点検表はPROBAST（4領域20問。開発は候補予測因子あたりイベント20以上、外部検証はイベント100以上が目安）、書くときはTRIPOD+AI（回帰も機械学習も同じ27項目）です [PROBAST AnnInternMed2019] [TRIPOD+AI BMJ2024]。較正の読み方・再較正・SMRの作法は[重症度スコアと予後予測](#)で扱います。

根拠を見る（表6：主要モデルの識別能・較正・外的妥当性）

表6 | 主要モデルの識別能・較正・外的妥当性

モデル／予測主体	対象	識別能	較正	外的妥当性
医師の主観的予測	SICS 827例	AUC 0.68 (0.63–0.73)	—	単一コホート [ノイズCC2025]
APACHE IV	同じ827例	AUC 0.83 (0.79–0.88)	—	同上（著者らの再解析）
APACHE III-j → JROD（再較正）	JIPAD 33,557例	0.915 → 0.917	SMR 0.48 → 1.00、Brier 0.047	内部検証（ブートストラップ）のみ [JROD JIC2021]
APACHE II／SAPS II／III-j／JROD	JIPAD COVID-19 444例	0.704／0.696 ／0.707／ 0.718	H-L検定すべ てp<0.001	新規疾患で両方とも不良 [COVIDスコアJIC2021]
GOSSIS-1／ APACHE-II／III／ JROD	JIPAD 2015– 2022	0.908／—／ 0.908／0.910	SMR 0.89／ 0.39／0.46／ 0.97	数少ない真の外部検証。神経疾患・外傷 で較正不良、パンデミック期に性能低下 [GOSSIS CCEExplor2025]
CISSS（15変数）	米国VA 534,001入室	0.848（0.844– 0.852）	SMR 1.00 （0.98– 1.02）、Brier 0.058	外的検証なし（95%超が男性） [CISSS-Fortis]
ANZROD／SOFA／ APACHE III	百寿者460例	0.90／0.80／ 0.78（ICU死 亡）	—	すべて内部導出 [百寿者CC2026]
急性低酸素性呼吸不 全の経過アーキタイ プ（XGBoost）	導出MIMIC-IV 3,938例／外 部検証6,480 例	3日目までに平 均≥0.78	—	独立2コホートで検証済み（まれ） [AHRFアーキタイプICM2026]
DNN+SHAP	JIPAD	ICU死亡0.94／ 院内死亡0.91	評価が薄い	上位20変数版の外部検証のコホートが 特定されていない [DNN-SHAP ACPM2022]
急性膵炎の「高リス ク軌道」モデル	ANZICS- CORE 開発 542例	0.827	Brier 0.148、低リ スク域で 95%CIが広い	外部検証なし。感度0.54 [膵炎軌道CC2025]
HLH-Risk- Calculator	3か国6施設 167例	初期重症度AUC 0.845／時点別 死亡の平均 0.866	—	検証43例・死亡イベント13件、特異度 55.6%は陰性者9人から。sIL-2Rの測定 率40%。外部検証なし [HLH-Calc ICM2026]


JRODの再較正（階層一般化加法モデル）は変数の重みを変えず、出力全体を実際の死亡率の水準に引き直す操作なので、識別能は前後でほとんど変わりません [JROD JIC2021]。新規疾患や単一疾患にしばらくとAUROCが下が

るのは、集団が均質になったためという読み方（spectrum effect）も成り立ち、「モデルが壊れた」のか「集団が均質化しただけ」かは分けて考えます。信頼区間が広い報告されていない数字を見たら、点推定より先に症例数とイベント数を確認めます。

4-5. 予定外入室からの72時間 — 作業診断を書き、翌朝に見直し、外した理由を1行で残す

判断そのものをその場で保証することはできませんが、後から検証できる形で残せば仕組みとして補正し続けられるので、作業診断・プロトコルから外した理由・カンファの発言順の3つを、既存のカルテと議事録に1行ずつ足します（図4） [ノイズCC2025]

[Bergl CCM2019]。



最大の穴は翌朝。予定外入室の診断エラーの3件に2件は24時間以内に気づけていない

図4. 予定外入室からの72時間 — 見直しの機会を時間軸に固定する。

図の読み方 — 灰色の2段が見直しの関門です。忙しい日ほど関門を飛ばしやすいので、忙しさを言い訳にせず、翌朝の確認を手順として固定します。非難しない文化が整わないうちに大がかりなノイズ監査を始めると、記録そのものが処罰の材料と受け取られかねないので、まずこの1行の記録を、誰の判断も裁かない前提で1～2か月回し、たまってから傾向を振り返ります。

表7 | 場面ごとの確認と次の一手

場面	確認すること	次の一手
「敗血症です」と申し送られた	どこ感染か／感染でないなら何か	感染源を言えなければ、膿瘍・穿孔・骨髓炎・心内膜炎を名指しで除外する
原因不明の増悪・呼吸不全	見落としの6疾患を除外したか	心電図をとったか（剖検例でICU滞在中にとられていたのは55%）
ECMO中・重症例の意識変化	鎮静で説明しきっていないか	頭部画像の閾値を下げる。剖検では生前登録の約5倍の頭蓋内出血
カンファで方針を決める	誰が最初に話したか	意見は同時に出し、最も影響力の強い人が最後に話す
プロトコルから外す	正当な個別化か、例外の作りすぎか	外した理由をカルテに1行残す。指示簿には目標値の横に根拠を一言添える
予測モデル・AIの論文を読む	AUC以外に何が書いてあるか	較正と外部検証の場所・例数を先に見る。書かれていなければ「書かれていない」と言う
観察研究・レジストリで因果を語る	曝露は時間依存か、組み入れに日数の基準がないか	不死時間バイアスと適応による交絡を先に疑う（§6-2）

§5 予測が結果を作る領域 — 予後の判断と治療中止の判断を分け、結論を急がない

予測モデルの3点をどれだけ丁寧に測っても足りない領域があります。予測そのものが治療方針を変え、その方針が予測を実現させてしまう場合です。典型は心停止後の神経予後予測で、手順の詳細は心停止後ケアの資料が正本です。

この章のポイント

- 1 予後予測と中止の話と同じ場で混ぜない
- 2 72時間以降に2つ以上で判断する
- 3 初回値だけで結論を出さない

5-1. 自己成就的予言 — 不良所見が中止を招き、中止が不良転帰を作り、予測が当たったように見える

心停止後の死亡の多くは脳死ではなく、「予後不良」という判断を受けた生命維持治療の中止（WLST）の後に起き、「マーカー不良→WLST→死亡」という経路ができると、マーカーの精度は自分が作った結果を当てているだけになりうるので、識別能も較正も前提が崩れます（図5） [心停止後予後予測CC2026]。




図5. 自己成就的予言。円環のどこにも誤りがないのに、全体として予測因子が転帰の原因の一部になる。

図の読み方 — AIの言葉でいえば、教師ラベルが「予測の結果として付けられた」状態です。同じ構造はフレイルを理由にした治療制限（**フレイルと高齢重症患者**）や、急性脳損傷後の早期の治療中止にも潜みます。「この予測は、伝えた瞬間に方針を変え、その変化が予測を実現させていないか」を一度立ち止まって問います。

5-2. 設計で中止を外すと — 14日以内に不良マーカー2つ以上なら良好転帰は0/16、初回値だけなら偽陽性18.2%

ドイツ8施設で28日以内にWLSTへ移行した患者を除外した101例では、14日以内に不良マーカーが2つ以上そろった16例に良好転帰はなく、繰り返し測った最終値で判断すると瞳孔+角膜反射の偽陽性率は3.0%、初回値だけでは18.2%でした（表8）

[心停止後予後予測CC2026]。

表8 | 早期のWLSTを除外した心停止後の神経予後予測（101例）

結果	数値
12か月転帰	不良（mRS 4–6）68例67.3%（うち死亡43例）／良好33例32.7%
14日以内に不良マーカー≥2個	良好転帰0/16。年齢調整OR 34.7（95%CI 4.11–4578、p=0.00010）
感度（14日窓）	2つの組み合わせは0.00～0.19。単独で最も高いのはEEG 0.44
7日以内だと	偽陽性が残る（1マーカー群5例、≥2マーカー群1例）
初回値だけで判断すると	偽陽性率が瞳孔＋角膜反射3.0%→18.2%、EEG 0%→10.0%
CRS-R（14日以内の最良値）の上乗せ	交差検証AUC 0.888→0.925（p=0.011）。効くのはマーカー0～1個の判定保留群だけ

OR 34.7の95%CI上限4578は準完全分離のためで、この点推定に臨床的な意味はほとんどなく、報告すべきは「16例中0例」という素の数字です [心停止後予後予測CC2026]。除外したWLST患者39例は、入室時には良好群とも不良群とも区別できませんでしたが（Bonferroni補正後すべて $p \geq 0.07$ ）、2週間で良好群とは似ないプロファイルに分かれました。

根拠を見る（表9：WLST患者と治療継続患者のマーカーの分かれ方）

表9 WLST患者と治療継続患者のマーカー（14日以内）			
指標	WLST患者	不良転帰（治療継続）	良好転帰（治療継続）
NSE中央値（μg/L）	81.6	29.6	20.3
SEP N20両側消失	48%	7%	0%
最良のCRS-R	1.0	4.0	17.0

自己成就が主因なら、WLST患者の中に良好群に似た患者がまとまっているはずでしたが、どのマーカーでも似ていませんでした。ただし著者自身が「観察研究である以上、自己成就のバイアスは完全には排除できない」と書いており、示されたのは「バイアスの向きが逆ではない」ことで、「マーカーが判断に影響しなかった」ことではありません。NSE 81.6対29.6対20.3という差は、「マーカーが重い患者ほどWLSTが選ばれた」という説明とも整合します [心停止後予後予測CC2026]。

5-3. 「72時間以降・2つ以上・中止の判断と分ける」は、単一指標のノイズと早期閉鎖への対策

ERC/ESICM 2025は、ROSC後72時間以降（GCS運動反応<6が前提）に、6項目（瞳孔＋角膜反射消失・N20 SSEP両側消失・高度に悪性のEEG・NSE・status myoclonus・画像）のうち2つ以上がそろったときにだけ不良と判断し、予後予測の会話とWLSTの会話を同じ場で混ぜないように求めています [ERC/ESICM2025]。

2つ以上を求めるのは「平均化でノイズが減る」の応用で（横方向）、繰り返し測るのは時間方向の平均化です。72時間は情報が出そう前に結論を固定するアンカリングへの予防線で、中止の判断との分離は自己成就の連鎖を運用で断つ設計です。0～1個のときは

家族にも「まだ分からない」を保ち、72時間・7日前後・12～14日の3点で見直します。手順の詳細は[心停止後ケア](#)が正本です。

！注意 — NSEのカットオフが割れているのは価値判断

ガイドラインは $>60 \mu\text{g/L}$ 、研究側は $\geq 90 \mu\text{g/L}$ で、割れているのは技術の差ではなく「偽悲観（本当は良くなる人を諦めること）をどれだけ避けたいか」という価値判断です。使っている測定系とカットオフがどちらの水準かを確認めます

[ERC/ESICM2025] [心停止後予後予測CC2026]。物差しそのものも更新中で、治療側の介入（低体温・非STEの即時冠動脈造影・ PaCO_2 やMAPの目標）が軒並み中立だった一方、予後予測では血中ニューロフィラメント軽鎖（NFL）・瞳孔計のNPI・拡散テンソル画像の白質FAが前進しています [心停止後焦点ICM2019]。

予後をまだ判定できない段階で悲観的に伝えたと、家族の心の準備が先回りし、その後の方針の議論が「もう良くなるのだから」という前提に流れます。早く伝えなかったと問われることへの恐れが踏み込みを生むこともあり、日本の医療者で訴訟への恐怖が強かったこと（§3-4）を踏まえると、説明のタイミングを型で決めておくことは、個々の医師の負担と説明のばらつきを同時に減らします。

§6 AIを3層に分けて読む — 予測AIは「何をすべきか」を言わず、生成AIは一貫性の外にある

AIは判断の誤りと判断の材料の両方に効きうる道具ですが、一枚岩ではありません。予測AI・行動可能なAI・生成AIの3層に分けないと、「AIが賢いから」と「一貫性が効いているから」を取り違えます（表10） [AI未来ICM2023]。

この章のポイント

- 1 どの層のAIかを最初に言う
- 2 出力が意思決定に入るかで線を引く
- 3 出力を誰が検証するかを先に決める

表10 | AIを3層に分けて読む

層	できること	できないこと・注意
予測AI	「起こる確率」の早期警告	「何をすべきか」は言えない。関連にしか依拠しないため [AI未来ICM2023]
行動可能なAI	治療の選択肢を比べる＝因果推論	観察データでは時間依存性の交絡を排除しきれない。現実的な射程は特定の患者群の特定の判断に限った狭いAI [AI未来ICM2023]
生成AI・LLM	記録の整形・編集・要約、明示された事実の抽出	ハルシネーション、プライバシー、バイアスの再生産、deskilling [ChatGPT ICM2023]

6-1. 予測AI — 確率は告げても、何をすべきかは導けない

予測AIは関連（association）だけに依拠するので「何をすべきか」を導けず、「緩和ケアのコンサルトとノルアドレナリンの投与はどちらも死亡を強く示唆するが、どちらかを止めれば死亡確率が下がると考えるのは合理的でない」という例がその限界を示します [AI未来ICM2023]。

JIPADで学習した深層学習モデルはICU死亡AUC 0.94・院内死亡0.91で、ICU退室からの日数によらず1年を通じて0.91～0.95を保ち、ゲーム理論に基づくSHAPで寄与の大きい順に選んだ上位20変数だけのモデルでも従来のスコアより高いAUCでした [DNN-SHAP ACPM2022]。一方で、導入で外部検証と校正の不足を問題にしながら報告の中心はAUCで、上位20変数の外部検証のコホートも明示されていません。§4-4の3点は、予測AIの論文そのものにも向けます。

6-2. 行動可能なAI — 因果を言うには時間依存性の交絡を越える必要があり、観察データは「直せる」こともある

ICUの治療は逐次的な意思決定の連鎖なので、治療の選択肢を比べるAIは単純な回帰や傾向スコアマッチングでは足りない時間依存性の交絡に向き合う必要があり、強化学習で導いたバソプレシン開始ルール（ルールに近い開始で院内死亡の調整OR 0.81、0.73–0.91）も、プロトコルの根拠ではなく仮説として扱います [AI未来ICM2023] [バソプレシンRL JAMA2025]。

このルールは臨床医より「多くの患者に、早く、低いノルアドレナリン用量で」バソプレシンを始めることを提案しました（開始割合87%対31%、開始までの中央値4時間対5時間、開始時の用量0.20対0.37 µg/kg/min） [バソプレシンRL JAMA2025]。「早く・低用量から」は、重症度の低い患者にバソプレシンが入りやすいという交絡と区別しにくい点に注意します。

反対側の例が重症患者の蛋白投与です。観察研究5本（各1,000例超）はどれも「多いほど良い」、RCT 3本（EFFORT Protein・PRECISE・TARGET Protein）はどれも利益なしという真逆の構図で、RCT 2,869本と観察研究3,924本を突き合わせたメタ疫学研究は両者の効果推定にほぼ差がないとしているので、「観察研究だから外れた」では説明できません [蛋白バイアスCC2026]。原因は表11の4つの解析上の欠陥で、同じレジストリを区分指数加法混合モデル（PAMM）で解き直すと、EFFORT Proteinの公表より前にRCTと整合する結果に達していました。蛋白量の推奨は重症患者の栄養療法が正本です。

表11 | 観察研究がRCTと食い違った4つの解析上の欠陥

欠陥	何が起きるか
時間平均した曝露（「1～12日目の平均投与量」）	時間の順序が消え、死亡の直前に投与を減らされた患者が「もともと低投与群」に入る [蛋白バイアスCC2026]
適応による交絡	重症度が投与量を決め、投与量が次の重症度を決める＝時間依存性の交絡
競合リスクの無視	生存してICUを出た患者を打ち切り扱いにすると、早く良くなった患者の情報がゆがむ
不死時間バイアス	組み入れ基準が「ICU在室N日以上」だと、そのN日を生き延びたこと自体が群分けと相関する

ナラティブレビューで新規データはなく、著者らは批判対象の再解析を自ら発表した当事者です [蛋白バイアスCC2026]。

6-3. 生成AI — 線は「誰向けか」ではなく「出力が意思決定に入るか」で引く

LLMは同じ入力に同じ出力を返さず、存在しない文献や引用を作ることがあるので、明示的に書かれた事実の抽出や記録の整形のように誤りを人が拾える用途から使い、出力が意思決定に入る用途では一次資料で検証し、患者識別情報を汎用のチャットに入れません [ChatGPT ICM2023]。

ICU退院サマリーから治験候補を抽出した研究では、患者データを外部に出さない院内運用（オープンウェイトのモデル+11回の多数決）で候補を1,342件から185件に絞り、PPV 72%、医師のレビュー時間を86%減らしました [治験マッチングCC2026]。効いたのは明示された事実の抽出（人工呼吸日数F1 0.966、妊娠1.000）で、症候群の判断（敗血症0.698、心不全0.759、神経筋疾患0.500）は人の仕事のまま残り、AIが落とした側は誰も確かめていないので、「人に渡す候補を絞る」ところで止めます。放射線科の症例問題313問をGPT-4に解かせると、病歴だけ22%・画像所見だけ57%・両方61%と、渡した情報の種類で正答率が3倍変わりました [放射線科問題Radiology2023]。

！注意 — 家族向けの平易な説明も「低リスク」ではない

ECMOについての家族の質問に4つのLLMを照会すると、専門家が満足とした割合は95%・80%・71%・61%とモデル間で大きく開き（ $p<0.001$ ）、合併症率を実測の5～10倍に見積もり（血管損傷 約1～5%→5～30%）、VV-ECMOの期間を短く言いました（19.6日→7～14日） [ECMO-LLM CC2026]。弱点は網羅性と共感で、面談で臨床医が担うべき2つです。評価者間一致はKappa 0.35（fair）、4問×4モデル×各1回の照会なので、モデルの序列そのものは引用できません。モデルは数か月で入れ替わります。

根拠を見る（表12：問いを分解して聞く TCEPFT／著者性と「人」の代替）

表12 | プロンプトを6要素で組み立てる（TCEPFT）

要素	意味
Task	何をさせるか（identify／summarize／compare）
Context	誰について、どの条件で（PICOのPにあたる）
Example	出力の方向を示す具体例
Persona	誰のための出力か
Format	箇条書きか、小見出しつきの段落か、表か
Tone	学術的か、平易か、簡潔か

EBMで毎日使うPICOと同じ「問いを分解して組み立てる」考え方で、Contextの疾患名だけを差し替えれば構造と読者とトーンを保ったまま使い回せます。コメントリーで、精度が上がることは検証されていません [TCEPFT JMLA2025]。ChatGPTを共著者欄に置いたPerspectiveは、資料の整理・初稿・校正では研究者を助けるが人の判断の代わりにはならず、重要な決定の前に専門家が見直すべきだと主張し、母語でない言語のテキストをAI剽窃検出器が「AI生成」と誤判定しうると指摘しました [AI著者CC2023]。家族の声をAIで模倣して意識のない患者に届ける構想は、医療者のレビューと承認を4段のパイプラインに組み込んでいますが、患者での評価はなく、家族が自分で録音した声との比較もありません [家族音声CC2023]。

6-4. AIと人の相互作用 — 心エコーAIの効果の正体はアンカリングで、聞けば動くと答え、測ればほとんど動かない

左室駆出率の初期評価をAIか検査技師かで盲検下に無作為化した試験では、最終評価までに5%超修正された割合がAI 16.8%、技師 27.2%（−10.4%、 $P<0.001$ ）で、効果の正体はAIが正しいことではなく、良い初期値に人が引きずられること（アンカリング）でした（表13） [心エコーAI Nature2023]。

表13 | 心エコーAIの盲検化RCTの主要結果

指標	AI	検査技師	差・P値
初期→最終評価で5%超の変化	16.8%	27.2%	−10.4% ($P<0.001$)
安全性の副次（過去の独立評価との絶対差）	6.29%	7.23%	−0.94 ($P<0.001$)
計測時間	0秒	119秒（中央値）	−131秒
EF 35%をまたいだ検査（事後解析）	1.3%	3.1%	$P=0.0004$

良い初期値を作業の上流に置くと下流の人の出力が安定するという構造は、申し送りやレポートの運用にも使えます。画質不良で左室をトレースできない274件（7.3%）はランダム化の前に除外されており、AIは「撮れた画像の計測」を代わっても、「使える画像かの判断」は代わっていません [心エコーAI Nature2023]。

ICP上昇予測の国際調査（236名・仮想シナリオ）では、80%確率のアラートで84.7%が何らかの行動をとり、行動を起こす確率の中央値は診断的介入70%（IQR 50–80）・治療的介入80%（70–90）、望む先行警告は30分（45.5%）、予測してほしいICPは22 mmHg（20–25）でした。58.7%は「パラメータが分からなくても精度の高いモデル」を選び、透明性より精度が前提と読めます [ICP-Aid ICM2025]。ところが非ICU病棟で敗血症の機械学習アラートを回した実装研究（362アラート）では、アラート後に新しい所見を認識したのは看護師24%・医療者13%で、大多数（55%・62%）は敗血症リスクの認識が変わらず、有用と答えたのは看護師42%・医師16%でした [敗血症アラートCCM2019]。閾値は前者を出発点にし、期待値は後者に置いて、導入後の行動の変化を実測します。

6-5. 監督責任 — never-skillingを防ぎ、導入前に12項目を問う

臨床推論や意思決定までAIに委ねると、自動化への過信（automation bias）、獲得した技能の喪失（deskilling）、本来身につける能力を最初から得ない（never-skilling）、誤った行動の強化（mis-skilling）の4つが起きるので、導入前に出力を誰がどう検証するかを含む12項目を確かめます（表14） [AI監督NEJM2025]。

never-skillingは実測され始めています。AI支援のPOCUS研修の対照試験6本・293人の系統的レビューでは、画像の取得は従来の指導と同等以上でしたが、撮れた画像で左室機能・心嚢液・容量状態を判定できた割合はAI群50.0%、従来81.8%でした（ $p=0.026$ ） [AI-POCUS研修CC2026]。研修の評価はAIを切った状態で、点数ではなく「その画像で判断できるか」で測ります。AIの警告が鳴ったときは、鳴った理由と見落としの6疾患を自分の頭で当てはめてから治療を選び、指導医は答え合わせだけでなく「その結論に至った理由」を聞きます。

表14 | AIを導入する前に問う12項目

#	項目	何を問うか
1	AIの型	予測AI・行動可能なAI・生成AIのどれか。予測AIに「何をすべきか」を期待していないか [AI未来ICM2023]
2	教師ラベルの質	ラベルは誰がつけたか。評価者間のばらつきを測ったか。一貫しない専門家判断で学習するとモデルに誤差が入る [Sylolypavan NPJDM2023]
3	外的妥当性	自施設のデータで較正を確かめたか。開発集団と自施設の患者像は変わらないか
4	上流の工程	AIが処理できる入力を誰がどう選んでいるか（画質不良の除外など）
5	アラートの閾値	何%で、何分前に鳴らすか。アラーム疲労を見積もったか
6	監督責任者	出力を誰が検証するか。誤った出力を臨床医に見せると判断の精度は下がる [Jabbour JAMA2023]
7	教育の設計	研修医のnever-skillingをどう防ぐか。推論を言葉にさせる仕組みがあるか
8	プライバシー	患者識別情報がモデル提供者に渡らない構成か
9	撤退基準	性能の劣化をどう検知し、いつ止めるか。スコアも15年で較正が劣化する [LastingLegacy ICM2022]
10	版と再評価の周期	生成AIはどのモデルのどの版をいつ評価したか。評価結果は数か月で古くなる
11	記録	出力が判断に実質的に影響したとき、とくに出力と違う判断をしたときの理由をカルテに残せるか [6つのルール BMJ2026]
12	段階導入と境界	サイレント運用→医師向けの決定支援→限定的な自動化の順で進めるか。自動化するなら安全境界・異常検知・容易なオーバーライド・監査証跡があるか。開発論文はTRIPOD+AIで報告され、PROBASTで高リスクでないか [生理学的人工呼吸WJCCM2026]

根拠を見る（責任の所在・普及の壁・人員計画・ケアのゴール）

英国法ではAIシステムそのものは訴えられず、責任は臨床医・医療機関・開発者・製造者に向かいます。医師が批判されうる場面は、使うべきでない場面で使った・不適切なシステムを使った・適切なシステムを相当の注意なく使った・使うべきときに使わなかった・AIの使用や代替手段について患者に重要な情報を伝えなかった、の5類型で、示された6つのルールは①正しい道具を選んで理解する ②患者情報を守る ③出力に従う前に入力を確認

かめる ④重要な場面では患者に伝える ⑤有用な記録を残す ⑥何か起きたら動く、です。法的な結論は英国のもので、日本にそのまま当てはまりません [6つのルール BMJ2026]。

人工呼吸の自動化を整理したミニレビューは、現時点のAIは決定支援と後ろ向き解析にとどまり自律制御は前向き評価が足りないとし、一回換気量・気道内圧・FiO₂などに事前の安全境界を置いてその範囲内でだけ自動調整を許す「境界つき自動化」を提案しました。後ろ向きデータで学習したモデルは施設の診療パターンを埋め込み、機種・波形のサンプリング周波数・プロトコルが変わると性能がずれます。新規データのないレビューなので、段階の順序は根拠ではなく設計の提案です [生理学的人工呼吸WJCCM2026]。

AIがICUで普及しない理由は、①データの質（ゴミを入れればゴミが出る、差別的バイアス、外部検証の実現可能性を事前に計画すること）②倫理的・法的側面（データ共有の法整備、医療機器としての認可）③教育の3つに集約され、どれか1つ欠けても進みません [AI普及障壁]。経済理論からは、AIが自動化するのは課題であって仕事ではなく、効率化は需要を増やしうる（ジェヴォンズの逆説）ので「AI導入＝増員不要」とは限らないと論じられていますが、効果量を示す研究ではありません [AI雇用NEJM2026]。PEEP設定へのAIとデジタルツインを論じたコメンタリーは、目標は時間と臓器の状態で変わり、「ケアのゴールは臨床医の専権事項」と結びます [PEEP-AI ICM2024]。AIが縮められるのは精密度（ノイズ）の側で、何を良しとするかという基準点は人が置き続けます。

§7 エビデンスと研究データにもノイズは乗る — 統合推定値は抽出されるのではなく、前提の置き方で作られる

ノイズは臨床医の頭の中だけで起きるわけではありません。同じ試験群を統合する人が違えば結論が変わり、研究データを作る工程にもばらつきがあります。プロトコルを改訂する根拠を読む側として押さえておきます。

この章のポイント

- 1 バイアスリスク層別の結果を探す
- 2 「差がない」の下の異質性を問う
- 3 データの出どころと作り方を確かめる

7-1. メタ解析はレビューアで結論が変わる — メラトニンは高リスク試験だけで効いて見えた

ICUせん妄予防のメラトニンで肯定的なレビューと「推奨するには不十分」とするレビューが食い違った主因はバイアスリスクの扱いで、ROB-2で層別すると高リスク試験RR 0.46 (0.29–0.73)、低リスク試験RR 0.86 (0.70–1.05)、交互作用P=0.01だったので、統合推定値には低バイアスリスク試験に限った推定値を必ず並べます [メタ解析Editorial CC2026]。

見かけの効果は高リスク試験に偏っており、leave-one-outでは1つの試験を外すと効果が逆向きに動きました

[メタ解析Editorial CC2026]。フォレストプロットの下のひし形を読み上げて終わりにせず、①バイアスリスク層別で結論が変わるか、②leave-one-outで推定値を動かしている試験はどれか、③最大で最も質の高い試験は何を示しているか、を確かめます。両者が同じ向きなら採用の後押しに、食い違うなら条件付きにとどめます。

7-2. 同じ2試験でも読み方は割れる — ハロペリドールは「治療」の言い方が割れ、運用は割れていない

MIND-USAとAID-ICUを突き合わせた論説は、死亡だけが食い違い（調整HR 1.02対調整RR 0.84）どちらも死亡を検出する検出力がないのでAID-ICUの死亡低下を根拠に推進するのは行き過ぎとし、12 RCTのベイズ+頻度論メタ解析は治療での死亡の臨床的に重要な利益の事後確率68%・重い有害事象の害2%として治療での使用を支持しました [ハロペリドールMIND-AID ICM2023]

[ハロペリドールメタ解析CC2025]。

予防では両者とも否定的で、QTc延長の害の確率は65%と本解析で最も高い値でしたが、同じQTcもリスク差で見れば26%でした [ハロペリドールメタ解析CC2025]。食い違いの源は、バイアスリスク、統計の枠組みと閾値の選び方、1つの巨大試験への依存（AID-ICUが治療パートの56%）です。予防投与はしない、危険な興奮には対症的に使う、という運用はどちらの読み方でも変わらず、言い方が割れても運用が割れない論点は「決着する必要がない」論点です。せん妄の薬の使い方はPADIS — 鎮痛・鎮静・せん妄が正本です。

7-3. 「差がない」の下には異質性が隠れうる — 効く群と害になる群が打ち消し合う

RCTの主要アウトカムは群全体の平均なので、効く群と害になる群が打ち消し合って隠れることがあり、強化早期離床のTEAM試験の二次解析では治療×予測の交互作用が $p=0.006$ で、死亡が34.0%下がる患者から39.3%上がる患者までの幅があり、三分位の平均治療効果は $-8.35\% \rightarrow -2.59\% \rightarrow +14.63\%$ と分かれました [TEAM異質性ICM2025]。

害の側を決めていたのは昇圧薬・深い鎮静（RASS低値）・糖尿病という「不安定さ」の組み合わせでした。ランダム化データなので交絡の心配はありませんが、各三分位の効果はどれも95%CIが0をまたぎ、無効だった試験の二次解析として著者らも仮説の生成と位置づけています [TEAM異質性ICM2025]。JIPADのRRTでも機械学習で効く群と害になる群が逆向きに分かれましたが、観察データからの異質性の推定は交絡に弱く、前向きの検証なしに適応の判断には持ち込めません [RRT異質性CCM2026]。RRTの始めどきはAKIと腎代替療法、早期離床は早期離床が正本です。

！注意 — その治療方針をとった人だけで性能を測らない

介入下の予測モデルを検証するときは、戦略から外れた時点で人工的に打ち切り、逆確率重み付けで「全員が従った世界」を再現して較正・c-index・Brierを測る必要があり、シミュレーションではこの手当てをしないと判別能の過大評価とscaled Brierの符号の反転が起きました。方法論の達成とモデルの臨床的価値は別で、応用例のモデル自体はc-index 0.561とほぼ情報がありませんでした [介入下予測Epi2024]。

7-4. 研究データを作る工程にもノイズがある — カルテレビューも測定であり、データベースは偏る

院内GPU上のLlama-3-8Bで腎摘8,366例・130,509ノートから病理・手術・放射線の14変数（136,425要素）を抽出すると手作業データベースと97.5%一致し、不一致2.5%を第三者が盲検で裁定すると14変数中10変数でLLMのほうが正しかったので、手

作業のカルテレビュー（抄読者間・抄読者内で10～42%ばらつく）も参照基準ではなく測定の1つとして扱います

[npjDigitMed2026]。

処理は7枚のA100で計82.1時間（1チャート約35秒）、人手で作直すと専従1名で約2年の見積もりでした。単施設・英語・泌尿器科コホートの後ろ向き検証で、施設や記載様式が変わればプロンプトの作り直しと検証が毎回要ります [npjDigitMed2026]。データベースの側も偏っており、2018～2025年の4,648本ではMIMIC-III/IVが84.6%、米国由来のデータベースが98.1%、著者国は中国が65.6%、欧州の3データベースは合計1.9%で、デザインは後ろ向き観察67.9%、手法はロジスティック回帰38.5%、主題は死亡予測52.0%・敗血症20.8%と、本数は45倍に増えても中身は均質でした [MIMIC書誌CC2026]。

根拠を見る（表15：データベース研究を読む3点／報告の質／集中治療AIの3つの波）

表15 | 「公開データベースで〇〇を予測した」論文を読む3点

確認点	読み方
単一のデータベースか、独立したデータセットで検証したか	MIMICは単施設のデータ。閾値や係数を持ち込む前に、日本のICUで再現するかを問う [MIMIC書誌CC2026]
非選択のICU死亡予測でAUROC 0.90 超か	相場は中央値0.798（最頻域0.75～0.85）。0.90超は情報漏洩・過学習・アウトカム定義の甘さをまず疑う
解析コードは公開されているか	再現性の最低条件。公開されていないモデルの数字は追試できない

AKIバイオマーカー研究の報告ガイドライン（STARD）への準拠率は54.5%で、AKIに特化したSTARDaki拡張がデルファイ合意で提案されました [STARDaki ICM2026]。重症治療のデータ共有とハーモナイゼーションについては、系統的レビューと修正デルファイで24原則が示されています [データ共有24原則CCM2025]。報告が壊れたデータで学習したモデルは、その壊れ方を学びます。患者レベルのデータを施設に残したまま標準化したクエリを配る連合型（欧州保健データスペース）も構想されていますが、ICUでの実装例はほぼなく、集計出力はまれなサブグループをばかすので表現型の発見とは衝突します [EHDS ICM2026]。

表16 | 集中治療AIの3つの波

波	内容	現状
第1の波	予測AI・タスク特化型の機械学習	到来したが臨床の変革には至らず
第2の波	生成AI・LLM・アンビエントスクライブ・エージェント型AI	到来しつつある
第3の波	確信があるときは推奨し、不確実なときだけ妥当な選択肢の間でランダム化して学ぶオンライン強化学習を診療に埋め込む構想	招待オピニオンで新規データなし。どこにも実装はない [第3の波ICM2026]

第3の波の議論から今できることは実装ではなく、誰が・いつ・どちらの選択肢を選び・その後どうなったかを欠損なく残すことで、記録が無ければ後からどんなAIも因果を推定できません。ベッド配分や優先順位づけも転帰に影響するので、「業務効率の用途だから低リスク」という分類も成り立ちません [第3の波ICM2026]。研究の上

流（仮説生成・実験計画・解析コード）を自動化するAIエージェントも現れ、ある報告は872～937時間の認知労働を2時間未満に圧縮しましたが、効率の向上と洞察の獲得は同じではなく、解析上の欠陥を高速に再生産する危険もあります [研究AI Nature2026]。

§8 落とし穴 — ラベルで止まる、数字だけを読む、流暢さを信じる

この分野で繰り返し起きる失敗は、§1～§7の枠組みのどれかに対応します。なぜ起きるかを先に理解すると、初めて見る失敗にも応用がききます。どれも悪意ではなく、時間に追われた現場の近道なので、個人の注意力ではなく型と仕組みで防ぎます。

8-1. ラベル・発言順・忙しさ — 推論が止まる3つの入口

申し送りの病名で鑑別を止める、上級医が先に意見を言う、忙しさを判断の誤りの言い訳にする、の3つはどれもバイアスと機会ノイズの入口なので、申し送りの型・司会の台本・翌朝の確認という手順に置き換えます [Bergl CCM2019] [ノイズCC2025]。

！注意 — ラベルで推論を止める

症候群アプローチは感度も特異度も低く、「診断がついた」という感覚が早期閉鎖を招きます。誤った作業診断の18件中7件が「敗血症」だったことを根拠に、「どこの感染か／感染でないなら何か」を言わせるのを申し送りの規則にします

[Bergl CCM2019]。

！注意 — カンファで上級医が最初に話す（話させる）

司会が「では部長から」と振るのが自然だから起きます。司会の台本を変え、自分が上級医になったら「最後に話す」が仕事です [ノイズCC2025]。

！注意 — 「今日は忙しかったから」で終える

機会ノイズは実在しますが、言い訳にすると原因の特定と改善策の設計が止まります。ノイズが乗りやすい場面を特定し、忙しい日ほど翌朝の確認を確実にを行う手順に変えます (§4-5)。

8-2. 数字の読み違い — AUCだけ、単発の測定、統合推定値、「観察研究だから」

AUROC 0.915のままSMR 0.48だったAPACHE III-j、AUROC 0.827でも感度0.54のモデル、初回値だけで偽陽性率18.2%の予後マーカーが示すとおり、1つの要約値で道具や結論を判断しないことが共通の対策です [JROD JIC2021] [肺炎軌道CC2025]

[心停止後予後予測CC2026]。

- AUCは感度と特異度のトレードオフ全体の要約で、実際に使う閾値での性能ではない。校正と外部検証の記載を先に探す

- ・単発の測定には測定・判読・タイミングのノイズが必ず乗る。指標を増やし（横）、繰り返し測る（縦）。特異度を作っているのは繰り返しで、指標そのものではない
- ・統合推定値は、バイアスリスク層別・leave-one-out・最大の試験の向きと並べて読む（§7-1）
- ・観察研究とRCTが逆なら、曝露は時間依存か・競合リスクは何か・組み入れ基準に日数が入っていないかを先に見る（§6-2）
- ・「平均して差がない」を「誰にも効かない」と読まない。異質性の検討があるかを確認する（§7-3）
- ・予測モデルが壊れる集団（新規疾患・末期腎不全・中毒・希少疾患・超高齢・単一の公開データベース由来）は重症度スコアと予後予測の特殊な集団の章で扱う

8-3. 流暢さと手順への過信 — LLMの数字を信じる、決めたプロトコルを見直さない

LLMは合併症率を実測の5～10倍に見積もっても流暢に、自信ありげに答え、プロトコルは作った時点の満足感が見直しの必要を覆い隠すので、どちらにも出力を検証する人と、性能の劣化を検知して更新する周期をあらかじめ決めておきます [ECMO-LLM CC2026] [LastingLegacy ICM2022]。

× 危険 — 患者識別情報を汎用のチャットに入れる

出力の正しさ以前に、プライバシーの問題です。院内で使うなら、患者データがモデル提供者に渡らない構成かを導入前に確かめ（表14の#8）、出力は一次資料で検証してから意思決定に入れます [ChatGPT ICM2023]。

表14の#9「撤退基準」はAIだけの話ではありません。輸液・鎮静・SBTなどの既存のプロトコルにも、性能の劣化を検知する仕組みと更新の周期を決めておきます。スコアが15年で較正を失うのと同じ理屈が、施設の手順書にも当てはまります。バイアスは意識すれば1人でも直せますが、ノイズは仕組みでしか直せません。

主要文献

本文中の出典タグ（筆頭著者または試験名・誌略＋年）に対応します。

- ・ Kahneman D, Sibony O, Sunstein CR. *Noise: A Flaw in Human Judgment*. 2021 (Noise2021)
- ・ ICUの判断の誤りとノイズ (Perspective) . *Crit Care*. 2025 — 同じ827例で医師AUC 0.68対APACHE IV 0.83、ノイズ監査の設計 (ノイズCC2025)
- ・ Cox EGM, et al. SICSコホートにおける臨床医の死亡予測. 2021 (Cox SICS2021)
- ・ Kahneman D, Klein G. Conditions for intuitive expertise: a failure to disagree. *Am Psychol*. 2009 (Kahneman&Klein2009)
- ・ Dawes RM. The robust beauty of improper linear models in decision making. *Am Psychol*. 1979 (Dawes1979) / Meehl PE. *Clinical versus Statistical Prediction*. 1954
- ・ Goldman L, et al. The value of the autopsy in three medical eras. *N Engl J Med*. 1983 (Goldman NEJM1983)
- ・ Tejerina E, et al. ICU死亡例の連続834剖検における臨床診断と剖検所見の乖離 (25年) . 2012 (Tejerina2012)
- ・ Bergl PA, et al. 予定外ICU入室256例の診断エラー. *Crit Care Med*. 2019 (Bergl CCM2019)
- ・ 重症患者の診断エラー (解説) . *Intensive Care Med*. 2025 (診断エラー解説ICM2025)
- ・ ICUの診断エラーをSEIPSで分解する (What's New) . *Intensive Care Med*. 2026 (SEIPS ICM2026)
- ・ 第二の犠牲者の日米比較 (傾向スコアマッチング) . *Crit Care*. 2026 (第二犠牲者CC2026)
- ・ ベッドサイド診療を取り戻す戦略. *N Engl J Med*. 2025 (ベッドサイドNEJM2025)

- COVID-19患者のECMO中の頭蓋内出血 — ドイツ剖検登録 (ECMO剖検DeRegCOVID)
- ショックの臨床徴候はどこまで使えるか (Letter・25研究67,894名) . *Intensive Care Med.* 2023 (ICM2023徴候SR)
- ショック患者へのポイントオブケアエコー (英国178 ICU) . *Intensive Care Med.* 2024 (エコー診断変更ICM2024)
- Ohbe H, et al. 入院を要する市中肺炎1,045例でのqSOFA・CURB-65・PSI. *J Intensive Care.* 2018 (qSOFA-CAP JIC2018)
- Quintairos A, Pilcher D, Salluh JIF. ICUスコアリングシステムの40年 (Lasting Legacy) . *Intensive Care Med.* 2022 (LastingLegacy ICM2022)
- Lambden S, Laterre PF, Levy MM, Francois B. SOFAスコアの成り立ちと臨床試験での測り方. *Crit Care.* 2019 (SOFA標準化CritCare2019)
- Endo H, et al. JROD 日本版死亡リスク予測モデル (JIPAD 33,557例) . *J Intensive Care.* 2021 (JROD JIC2021)
- COVID-19では従来の重症度スコアが機能しない (Letter・JIPAD 444例) . *J Intensive Care.* 2021 (COVIDスコア JIC2021)
- Tohyama T, et al. GOSSIS-1のJIPAD外部検証. *Crit Care Explor.* 2025 (GOSSIS CCEExplor2025)
- 簡易重症度スコアCISSSの開発と内部検証 (CISSS-Fortis)
- 百寿者のICU入室460例 (ANZICS) . *Crit Care.* 2026 (百寿者CC2026)
- 急性低酸素性呼吸不全の4つの経過アーキタイプ. *Intensive Care Med.* 2026 (AHRFアーキタイプICM2026)
- 深層学習でICU死亡を予測しSHAPで説明する (JIPAD) . *Anaesth Crit Care Pain Med.* 2022 (DNN-SHAP ACPM2022)
- 急性膵炎ICU患者の高リスク軌道の予測 (ANZICS-CORE) . *Crit Care.* 2025 (膵炎軌道CC2025)
- 二次性HLHの経過と死亡を予測する機械学習ツール (HLH-Risk-Calculator・167例) . *Intensive Care Med.* 2026 (HLH-Calc ICM2026)
- 公開ICUデータベース研究の構造的偏り (書誌計量・4,648本) . *Crit Care.* 2026 (MIMIC書誌CC2026)
- Moons KGM, et al. PROBAST: Explanation and Elaboration. *Ann Intern Med.* 2019 (PROBAST AnnInternMed2019)
- Collins GS, et al. TRIPOD+AI statement. *BMJ.* 2024 (TRIPOD+AI BMJ2024)
- 早期WLSTを除外した心停止後の神経予後予測 (101例) . *Crit Care.* 2026 (心停止後予後予測CC2026)
- ERC・ESICM 心停止後ケアガイドライン2025. *Resuscitation.* 2025 (ERC/ESICM2025)
- 心停止後ケアの焦点 (エディトリアル) . *Intensive Care Med.* 2019 (心停止後焦点ICM2019)
- 集中治療における人工知能の未来 (What's New) . *Intensive Care Med.* 2023 (AI未来ICM2023)
- ChatGPTは集中治療医の診療をどう変えうるか (エディトリアル) . *Intensive Care Med.* 2023 (ChatGPT ICM2023)
- 強化学習で導いたバソプレシン開始ルール. *JAMA.* 2025 (バソプレシンRL JAMA2025)
- 観察研究の「蛋白は多いほど良い」はバイアスの産物か (ナラティブレビュー) . *Crit Care.* 2026 (蛋白バイアス CC2026)
- LLMがICU退院サマリーから治験候補を抽出する. *Crit Care.* 2026 (治験マッチングCC2026)
- 手作業のカルテレビューは終わりの始まりか — 院内LLMで14変数を抽出. *npj Digit Med.* 2026 (npjDigitMed2026)
- GPT-4は放射線科の症例問題を解く (313問) . *Radiology.* 2023 (放射線科問題Radiology2023)
- ECMOについての家族の質問に4つのLLMはどう答えたか (Correspondence) . *Crit Care.* 2026 (ECMO-LLM CC2026)
- PICO原則を生成AIのプロンプトに組み込む (TCEPFT) . *J Med Libr Assoc.* 2025 (TCEPFT JMLA2025)
- AIは科学論文の執筆に使えるか (Perspective) . *Crit Care.* 2023 (AI著者CC2023)
- 家族の声をAIで再現する構想 (コメント) . *Crit Care.* 2023 (家族音声CC2023)
- AIによる心機能評価対検査技師 (盲検化RCT) . *Nature.* 2023 (心エコーAI Nature2023)
- AIによるICP上昇予測に臨床医はどう反応するか (ICP-Ald国際調査・236名) . *Intensive Care Med.* 2025 (ICP-Ald ICM2025)

- 敗血症予測の機械学習アラートの実装研究 (EWS 2.0) . *Crit Care Med.* 2019 (敗血症アラートCCM2019)
- 臨床でAIを監督する教育戦略. *N Engl J Med.* 2025 (AI監督NEJM2025)
- AI支援のPOCUS研修の系統的レビュー (6試験293人) . *Crit Care.* 2026 (AI-POCUS研修CC2026)
- Sylolypavan A, et al. 教師ラベルのノイズ. *NPJ Digit Med.* 2023 (Sylolypavan NPJDM2023)
- Jabbour S, et al. 誤ったモデル出力の提示は臨床医の診断精度を下げる. *JAMA.* 2023 (Jabbour JAMA2023)
- AIを使う医師のための6つのルール (オピニオン) . *BMJ.* 2026 (6つのルール BMJ2026)
- 生理学で導く人工呼吸と境界つき自動化 (ミニレビュー) . *World J Crit Care Med.* 2026 (生理学的人工呼吸 WJCCM2026)
- AIがICUで普及しない3つの理由 — データの質・倫理的法的側面・教育 (AI普及障壁)
- AIは臨床の働き手を減らすとは限らない (Perspective) . *N Engl J Med.* 2026 (AI雇用NEJM2026)
- PEEP設定にAIとデジタルツインを使う準備はできているか (Correspondence) . *Intensive Care Med.* 2024 (PEEP-AI ICM2024)
- メタ解析が食い違うとき (Editorial) . *Crit Care.* 2026 (メタ解析Editorial CC2026)
- ハロペリドールとせん妄 — MIND-USAとAID-ICU (What's New) . *Intensive Care Med.* 2023 (ハロペリドールMIND-AID ICM2023)
- ハロペリドールはせん妄の治療を支持し予防を支持しない (ベイズ+頻度論メタ解析・12 RCT) . *Crit Care.* 2025 (ハロペリドールメタ解析CC2025)
- 強化早期離床は誰に効くかで真逆になる (TEAM二次解析) . *Intensive Care Med.* 2025 (TEAM異質性ICM2025)
- RRTの効果は患者によって真逆だった (JIPAD・機械学習) . *Crit Care Med.* 2026 (RRT異質性CCM2026)
- 介入下予測モデルの性能検証 (方法論) . *Epidemiology.* 2024 (介入下予測Epi2024)
- AKIバイオマーカー研究の報告の質とSTARDaki (デルファイ合意) . *Intensive Care Med.* 2026 (STARDaki ICM2026)
- 重症治療のデータ共有・ハーモナイゼーション24原則 (SCCM Data Science Campaign) . *Crit Care Med.* 2025 (データ共有24原則CCM2025)
- 連携されたICUデータと欧州保健データスペース (ナラティブレビュー) . *Intensive Care Med.* 2026 (EHDS ICM2026)
- 必要なときだけランダム化する強化学習が集中治療AIの第3の波 (What's New) . *Intensive Care Med.* 2026 (第3の波 ICM2026)
- AIエージェントが科学的発見を自動化する. *Nature.* 2026 / AIは人間なしでは良い科学ができない (エディトリアル) . *Nature.* 2026 (研究AI Nature2026)